



# Universidad Central del Ecuador

## FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS Sistemas De Información

### Documento de Modelos

#### Estudiante:

- Luis Angel Gaona Cumbicus  
[lagaona@uce.edu.ec](mailto:lagaona@uce.edu.ec)
- Raul Alexander Pazos Erraez  
[rapazos@uce.edu.ec](mailto:rapazos@uce.edu.ec)
- Cristian Daniel Toca Rocha  
[cdtoca@uce.edu.ec](mailto:cdtoca@uce.edu.ec)
- Marlon Josue Espinosa Mancero  
[mjespinosam@uce.edu.ec](mailto:mjespinosam@uce.edu.ec)

#### Docente:

- PhD, Jefferson Tarcisio Beltrán Morales  
[jtbltran@uce.edu.ec](mailto:jtbltran@uce.edu.ec)

**Asignatura:** Minería de datos

**Paralelo:** S8-P2

**Fecha:** sábado 13 de julio de 2024





# **Generative AI-Powered Economic Impact Analysis System (GEIA)**

*Fecha:13/07/2024*



## Contenido

<b>HOJA DE CONTROL .....</b>	<b>4</b>
<b>Historial de Cambios .....</b>	<b>4</b>
<b>Introducción.....</b>	<b>5</b>
<b>Resumen.....</b>	<b>7</b>
<b>Conclusión .....</b>	<b>8</b>

**HOJA DE CONTROL**

Organismo	Universidad Central Del Ecuador		
Proyecto	Generative AI-Powered Economic Impact Analysis System ( <b>GEIA</b> )		
Entregable	Documento de modelos		
Autor	Luis Angel Gaona Cumbicus		
Versión/Edición	V1.0	Fecha Versión	13/07/2024
Aprobado por		Fecha Aprobación	...../...../.....
		N.º Total de Páginas	9

**Historial de Cambios**

Fecha	Autor	Organización	Descripción



## Introducción

Este documento presenta una variedad de métodos para el análisis de series de tiempo interrumpidas utilizando distintos paquetes en Python. Cada método proporciona una forma única de modelar y evaluar el impacto de eventos adversos en series temporales.

Modelo	Descripción	Funcionamiento Detallado	Aplicaciones Comunes
<b>CausalImpact</b>	Herramienta de análisis de impacto causal basada en el enfoque bayesiano, desarrollada por Google. Permite evaluar el impacto de una intervención sobre una serie de tiempo comparando la evolución observada con una predicción contrafactual.	<b>1. Definición de Períodos:</b> Pre-Intervención y Post-Intervención. <b>2. Modelado Contrafactual:</b> Ajuste del modelo en el período pre-intervención para prever cómo habría evolucionado la serie. <b>3. Comparación y Evaluación:</b> Comparación de la serie observada con el modelo contrafactual para determinar el efecto del evento.	Evaluación de campañas publicitarias, políticas públicas, eventos adversos como crisis económicas o pandemias.
<b>statsmodels (ARIMA)</b>	Biblioteca para análisis estadístico en Python que incluye el modelo ARIMA, útil para modelar y predecir series temporales con patrones de tendencia y estacionalidad.	<b>1. Preparación de Datos:</b> Organización en una serie temporal con índice de fecha. <b>2. Selección del Modelo ARIMA:</b> Identificación de parámetros AR, I, MA. <b>3. Estimación de Parámetros:</b> Estimación y diagnóstico del modelo. <b>4. Predicción:</b> Generación de pronósticos y evaluación.	Predicción de precios de acciones, tasas de interés, PIB, inflación, demanda en manufactura y ventas en retail.
<b>bsts (Bayesian)</b>	Permite ajustar modelos estructurales bayesianos a series de tiempo, descomponiendo la serie en componentes como tendencia,	<b>1. Preparación de Datos:</b> Organización de la serie para el ajuste. <b>2. Definición del Modelo:</b> Componentes estructurales como tendencia y estacionalidad.	Modelado de estacionalidades complejas, impacto de eventos



## MINERIA DE DATOS

<b>Structural Time Series)</b>	estacionalidad y efectos de intervención.	<b>3. Ajuste del Modelo:</b> Uso de métodos bayesianos para estimar el modelo. <b>4. Análisis y Evaluación:</b> Evaluación del modelo usando análisis de residuos.	específicos, evaluación de tendencias a largo plazo.
<b>pmdarima</b>	Biblioteca para automatizar la selección de modelos ARIMA, facilitando el ajuste automático de parámetros para el modelo ARIMA, incluyendo componentes estacionales.	<b>1. Preparación de Datos:</b> Organización y división en conjuntos de entrenamiento y prueba. <b>2. Automatización del Ajuste del Modelo:</b> Selección automática de parámetros. <b>3. Validación y Predicción:</b> Evaluación del modelo y generación de previsiones.	Forecasting de ventas en retail, datos económicos como inflación y tasas de empleo, análisis y previsión de precios de activos y tasas de interés.
<b>Prophet</b>	Desarrollado por Facebook, diseñado para manejar series temporales con patrones estacionales y efectos de eventos. Incluye componentes para tendencias y estacionalidades anuales, semanales y diarias.	<b>1. Preparación de Datos:</b> Estructuración en columnas ds (fecha) y y (valor observado), incluyendo eventos especiales. <b>2. Ajuste del Modelo:</b> Componentes de tendencia, estacionalidad y eventos. <b>3. Predicción y Evaluación:</b> Generación de pronósticos y evaluación de precisión.	Predicción de demanda en retail y servicios, análisis de tráfico web, evaluación del impacto de campañas de marketing y promociones.

**Resumen**

<b>Modelo</b>	<b>Propósito</b>	<b>Aplicación para Impacto de Intervención</b>
<b>CausalImpact</b>	Analizar el impacto de una intervención en una serie de tiempo utilizando un enfoque bayesiano.	Estima cómo habría evolucionado la serie de tiempo sin la intervención y calcula el impacto neto comparando los datos reales con los contrafactuales.
<b>ARIMA</b>	Modelar y prever una serie de tiempo basada en sus valores pasados y errores.	Prevé la serie de tiempo y compara las predicciones con los datos reales después de la intervención para estimar el impacto.
<b>BSTS (Bayesian Structural Time Series)</b>	Modelar una serie de tiempo mediante componentes estructurales y estimar el impacto de eventos o intervenciones.	Estima cómo habría evolucionado la serie de tiempo sin la intervención y mide el impacto comparando el modelo ajustado con los datos reales.
<b>pmdarima (AutoARIMA)</b>	Automatizar la selección de parámetros para el modelo ARIMA.	Prevé la serie de tiempo automáticamente y compara las predicciones con los datos reales después de la intervención para evaluar el impacto.
<b>Prophet</b>	Modelar series de tiempo con estacionalidades y tendencias robustas, desarrollada por Facebook.	Ajusta el modelo a los datos históricos y prevé el futuro, luego compara las predicciones con los datos reales después de la intervención.



**CausalImpact:** Directamente diseñado para evaluar el impacto de intervenciones al comparar datos reales con un modelo contrafactual.

**ARIMA:** Utilizado para prever y comparar predicciones con datos reales para inferir el impacto de la intervención.

**BSTS:** Similar a CausalImpact, proporciona una medida del impacto mediante la comparación entre el modelo ajustado y los datos reales.

**pmdarima (AutoARIMA):** Facilita la selección automática del modelo ARIMA y puede usarse para evaluar el impacto al comparar previsiones con datos reales.

**Prophet:** Adecuado para datos con estacionalidad y tendencias, y se utiliza para prever el impacto mediante la comparación entre previsiones y datos reales.

### Conclusión

En el análisis de series temporales interrumpidas, se han explorado diversas técnicas y herramientas para evaluar el impacto de intervenciones o eventos en datos históricos. Entre los modelos analizados, **CausalImpact** y **Prophet** se destacan por sus capacidades específicas y ventajas en el contexto de análisis de impacto.

#### CausalImpact

Es una herramienta avanzada basada en el enfoque bayesiano que permite evaluar el impacto de una intervención al comparar la evolución observada de una serie temporal con una predicción contrafactual. Su capacidad para modelar y comparar escenarios contrafactuales proporciona una comprensión profunda del efecto de eventos específicos, como campañas





publicitarias o políticas públicas. Este modelo es especialmente útil en situaciones donde la intervención tiene efectos potencialmente complejos y no lineales sobre la serie temporal.

### **Prophet**

Desarrollado por Facebook, es una herramienta poderosa para el modelado de series temporales que maneja patrones estacionales y efectos de eventos de manera eficiente. Es particularmente adecuado para datos con estacionalidades complejas y la inclusión de eventos especiales. Su flexibilidad en la modelización de tendencias y estacionalidades lo convierte en una opción excelente para predecir y analizar el impacto de intervenciones en una serie temporal, especialmente cuando se trata de datos con patrones estacionales y efectos de eventos.